Inteligencia Artificial Avanzada para la Ciencia de Datos

Raúl Emiliano Guzmán Acevedo A01754602

ITESM CEM

Grupo: 101

Instituto Tecnológico y de Estudios Superiores de Monterrey

Introducción

El código presentado realiza un análisis de regresión lineal para predecir el tiempo de vuelta de carros de carreras basado en su peso, y posteriormente clasifica si un vehículo es un carro de carreras o no. La regresión lineal se implementa utilizando un algoritmo de descenso de gradiente, y se evalúan los resultados mediante una matriz de confusión.

Importación de Bibliotecas y Carga de Datos

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay, precision_score, recall_score, f1_score, accura
```

[1] Python

```
# Importar el set de datos para su correcto manejo
df = pd.read_excel('/Users/raulguzman/Documents/Escuela/Septimo/proyectos/IA-Avanzada-Modulo-2/IA-Avanzada-Modulo-2/c
df
```

[3] Python

	Peso (kg)	Tiempo de vuelta (s)	Carro de carreras
0	1099.632095	63.771502	No
1	1560.571445	136.369249	No
2	1385.595153	97.722718	Sí
3	1278.926787	121.028483	Sí
4	924.814912	168.907977	No
...	...	...	...
95	1195.036477	101.905149	Sí

- **NumPy y Pandas**: Se utilizan para la manipulación y análisis de datos.
- **Matplotlib**: Se usa para la visualización de resultados.
- **scikit-learn**: Provee herramientas para la partición de datos y la evaluación del modelo mediante métricas de rendimiento y la matriz de confusión.

Preprocesamiento de Datos

```
"""
Se dividndo los datos en dos conjuntos, uno de entrenamiento y otro de prueba.
Se selecciona el peso del carro como variable independiente y el tiempo de vuelta como variable dependiente.

Se separan los datos en 70% para entrenamiento y 30% para prueba.
"""
x =np.array(df['Peso (kg)'])
y =np.array(df['Tiempo de vuelta (s)'])
carro = np.array(df['Carro de carreras'])

# Separar los datos en entrenamiento y prueba.
x_train, x_test, y_train, y_test, carro_train, carro_test = train_test_split(x, y, carro, test_size=0.3, random_stat
```

Las características (x), el objetivo (y) y las etiquetas (carro) se extraen del DataFrame. Posteriormente, los datos se dividen en conjuntos de entrenamiento y prueba, reservando el 30% de los datos para la prueba.

Implementación del Algoritmo de Descenso de Gradiente

```python
"""
Definimos los parámetros iniciales para el modelo de regresión.

Parametros:
- m: La pendiente del modelo.
- b: La linea y que intersecta con la regresión lineal.
- epochs: Iteraciones que se hacen.
- alpha: El learning rate para el descenso de gradiente.
- tolerance: La tolerancia para la convergencia del modelo.
- n_t: Número de datos de entrenamiento.

"""
#Parametros iniciales para el modelo de regresion
m = 0
b = 0
epochs = 10000
alpha = 0.0000001
tolerance = 1e-6
n_t = len(x_train)
```

Python

El algoritmo de descenso de gradiente se utiliza para encontrar la pendiente (m) y la intersección (b) de la recta que mejor ajusta los datos de entrenamiento

```python
"""
Algoritmo de descenso de gradiente

Este código implementa el algoritmo de descenso de gradiente para ajustar una línea recta a un conjunto de datos.
Utiliza la fórmula y = mx + b para calcular la predicción y el error.
Luego, calcula el gradiente de los parámetros m y b y los actualiza utilizando la tasa de aprendizaje alpha.
El algoritmo se repite durante un número determinado de épocas previamente extablecidas hasta que se alcanza la conve
se supera la tolerancia.

Durante la ejecución, se imprimen los valores de los parámetros cada 100 iteraciones.
"""

for epoch in range(epochs):
    # Calculo de la prediccion y el error
    y_pred = m * x_train + b
    error = y_pred - y_train
    # Calculo del gradiente
    grad_m = (1/n_t) * sum(error * x_train)
    grad_b = (1/n_t) * sum(error)
    # Actualizacion de los parametros
    m = m - alpha * grad_m
    b = b - alpha * grad_b
    # Verificar la convergencia
    if abs(alpha*grad_m) < tolerance and abs(alpha * grad_b) < tolerance:
        print('Converge en la iteracion:', epoch)
        break
    # Imprimir valores de los parametros cada 100 iteraciones
    if epoch % 100 == 0:
        print(f'Iteracion: {epoch+1}, m = {m}, b = {b}')
```

El algoritmo itera hasta 1000 veces o hasta que la actualización de los parámetros sea menor que la tolerancia definida, al finalizar, se imprimen los valores finales de m y b

Clasificación y Evaluación

```python
# Clasificador
pred_train = m * x_train + b  # Predicciones para los datos de entrenamiento
clasificador_carr_t = np.where(y_train > pred_train, "Sí", "No")
matriz = confusion_matrix(carro_train, clasificador_carr_t, labels=["Sí", "No"])
disp = ConfusionMatrixDisplay(confusion_matrix=matriz, display_labels=["Carro de carreras", "No es carro de carreras"
```

Python

```python
disp = disp.plot(cmap=plt.cm.Blues)
plt.title("Carros")
plt.show()
```

Python

```python
# Precision, recall y f1-score
precision = precision_score(carro_train, clasificador_carr_t, pos_label="Sí")
recall = recall_score(carro_train, clasificador_carr_t, pos_label="Sí")
f1 = f1_score(carro_train, clasificador_carr_t, pos_label="Sí")
```

```python
print(f'Precision: {precision}')
print(f'Recall: {recall}')
print(f'F1-score: {f1}')
```

Se calcula la predicción y se evalúa el modelo.

Gráfica

```
plt.scatter(x_train[carro_train == 'Sí'], y_train[carro_train == 'Sí'], color='red', label='Carro de carreras')
plt.scatter(x_train[carro_train == 'No'], y_train[carro_train == 'No'], color='blue', label='No es carro de carreras')
plt.scatter(x_train[clasificador_carr_t == 'Sí'], y_train[clasificador_carr_t == 'Sí'], color='green',marker='x', label='Clasifica
plt.scatter(x_train[clasificador_carr_t == 'No'], y_train[clasificador_carr_t == 'No'], color='purple',marker='x', label='Clasifi
plt.plot(x_train,pred_train, color='black', label='Recta de regresión')

plt.xlabel('Peso')
plt.ylabel('Tiempo de vuelta')
plt.title('Regresión Lineal con Clasificador')
plt.legend()
plt.grid(True)
plt.show()
```

Python

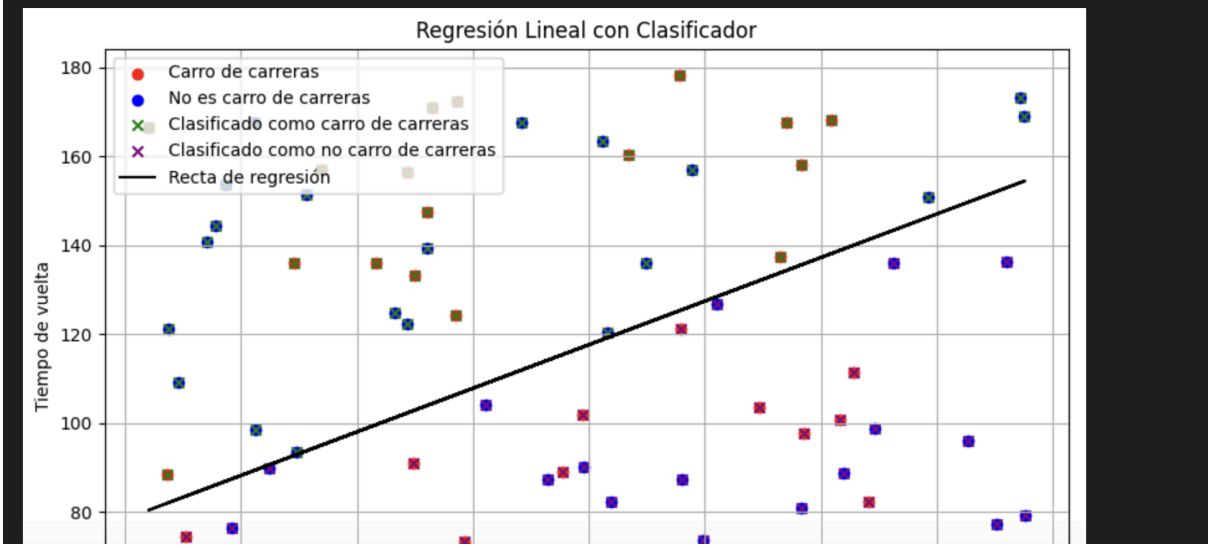

Se repite el proceso con el set de prueba de los datos.